

מבוא ללמידה חישובית – תרגיל בית 1

שם: דורי רימון

ת"ז: 323996843

אלגברה לינארית:

שאלה 1:

אזכור 1

אייזנשטיין כי עבור מטריצה סימטרית A , $A = XX^t$, $\Leftrightarrow A$ היא PSD.

\Leftarrow נניח כי $A = XX^t$. יבואו v וקטור v .

$$v^t A v = v^t X X^t v = (X^t v)^t (X^t v) = \|X^t v\|^2 \geq 0$$

ומכאן A היא PSD. מכאן נובע:

\Rightarrow נניח כי $v^t A v \geq 0, \forall v$. נסמן את הקוטורים הסדרים λ_i של A - $\lambda_i \geq 0, i=1, \dots, n$ - הם הערכים העigen של A .

$$\forall i=1, \dots, n, \quad 0 \leq v_i^t A v_i = v_i^t \lambda_i v_i = \lambda_i \|v_i\|^2$$

$\Rightarrow \lambda_i \geq 0$

הערה, מכאן נובע כי:

אם מתקנה שקלרית היא 0 , v נשן וסדר אחר הערכים λ_i של A , מתקנה זה

הערה נוסף וקטור הערכים λ_i הנותרים היא סכימה λ_i של הערכים λ_i של A ומכאן $\lambda_i \geq 0$.

$$\Rightarrow D = \begin{pmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{pmatrix} = \begin{pmatrix} \sqrt{\lambda_1} & & \\ & \ddots & \\ & & \sqrt{\lambda_n} \end{pmatrix} \begin{pmatrix} \sqrt{\lambda_1} & & \\ & \ddots & \\ & & \sqrt{\lambda_n} \end{pmatrix} =$$

$$= \hat{D} \cdot \hat{D} = \hat{D}^t \cdot \hat{D}$$

$$\Rightarrow A = Q D Q^t = Q \hat{D}^t \hat{D} Q^t = (\hat{D} Q^t)^t (\hat{D} Q^t) = X^t X$$

$\Rightarrow X = \hat{D} Q^t$

* נסמן $y = X^t$ ונראה כי נוסחה $A = y y^t$.

הסתברות ואינפי:

שאלה 1:

אורח 1

נחשב סכום (סכום) וסיכוי (סיכוי) ונחשב "זכר"

$$x^t A x = x^t \begin{pmatrix} \sum_{j=1}^n A_{1j} x_j \\ \vdots \\ \sum_{j=1}^n A_{nj} x_j \end{pmatrix} = \sum_{i=1}^n x_i \cdot \left(\sum_{j=1}^n A_{ij} x_j \right) =$$

$$= \sum_{i=1}^n \sum_{j=1}^n A_{ij} x_i x_j$$

וסיכוי, נכנס אר - תלמידה הנכונה

$$\frac{\partial x^t A x}{\partial x_i} = 1 \cdot \underbrace{\sum_{j=1}^n A_{ij} x_j}_{\text{קוסינוס היחיד}} + 1 \cdot \underbrace{\sum_{m=1}^n A_{mi} x_m}_{\text{קוסינוס היחיד}} = (A + A^t) x_i$$

קוסינוס היחיד

קוסינוס היחיד

אבר טרנספוזיט

טרנספוזיט הפוך

המאטריצה

כיוון זווית - זמן

כיוון זמן סדר סדר

והוא כיוון זמן

וקוסינוס אר - תלמידה

২. ফিল্ড

$$R(x)' = \frac{2 e^{2x}}{2x}$$

קצרתה ימים קטנים בך, יחול סודות וינסתרים לך הפסד - איום עצום

במחשבה (החזקה)!

אם כן מחליטה הסוכנות קיבלנו

נשמח להמליץ עליהם

→ So p_1 , ist eine $\mathbb{C} \langle x \rangle$ in $\mathbb{C} \langle x \rangle$ und $\mathbb{C} \langle x \rangle$ ist ein $\mathbb{C} \langle x \rangle$ -Modul.
 $\mathbb{C} \langle x \rangle$ ist ein $\mathbb{C} \langle x \rangle$ -Modul.

12.322 182

המקרה $\lambda = 0$ → $Eg(x) = E[x] = 0$, מכיוון שההתפלגות היא סימטרית.
 (הערה: במקרה $\lambda \neq 0$ יש להוסיף את $e^{\lambda x}$ במכנה).

$$Eg(x) = \int_{-\infty}^{\infty} x \cdot \frac{e^{\lambda x}}{E[e^{\lambda x}]} f_X(x) dx =$$

$$= \frac{1}{E[e^{\lambda x}]} \cdot \int_{-\infty}^{\infty} x \cdot e^{\lambda x} f_X(x) dx = \frac{E[x e^{\lambda x}]}{E[e^{\lambda x}]}$$

$$Eg(x^2) = \int_{-\infty}^{\infty} x^2 \cdot \frac{e^{\lambda x}}{E[e^{\lambda x}]} f_X(x) dx =$$

$$= \frac{1}{E[e^{\lambda x}]} \cdot \int_{-\infty}^{\infty} x^2 \cdot e^{\lambda x} f_X(x) dx = \frac{E[x^2 e^{\lambda x}]}{E[e^{\lambda x}]}$$

$$\text{Var}_g(x) = Eg(x^2) - Eg(x)^2 = \text{הוסיף את } \lambda \text{ בפרמטר} \\ = B(A)^4$$

$$\text{Var}_g(x) \leq B^2 \quad \text{: מכיוון שיש לנו גבולות}$$

$$Eg(x^2) \leq B^2 \quad \text{כיוון שיש לנו } C-B, B \text{ ו-} x \text{ קבוע}$$

$$\Rightarrow \text{Var}_g(x) = Eg(x^2) - Eg(x)^2 \leq Eg(x^2) \leq B^2$$

הערה:

$$* R(\lambda)'' = B^2$$

(c)

$$* R(0) = \ln(E[e^{0 \cdot X}]) = \ln 1 = 0$$

$$* R'(0) = \frac{E[Xe^{0 \cdot X}]}{E[e^{0 \cdot X}]} = E[X] = 0$$

$$\int_a^b f(x) dx = F(b) - F(a) \quad ; \text{ it is the main theorem of calculus}$$

$$\Rightarrow \int_0^\lambda \int_0^t R''(s) ds dt = \int_0^\lambda R'(t) - R'(0) dt = R(\lambda) - R(0) = R(\lambda)$$

$$; \int_0^\lambda \int_0^t R''(s) ds dt = \int_0^\lambda \int_0^t B^2 ds dt = \int_0^\lambda t \cdot B^2 dt = B^2 \frac{\lambda^2}{2}$$

$$\Rightarrow \ln(E[e^{\lambda X}]) \leq B^2 \frac{\lambda^2}{2} \Rightarrow E[e^{\lambda X}] \leq e^{B^2 \cdot \frac{\lambda^2}{2}}, \quad \forall \lambda \in \mathbb{R}$$

Q.E.D.

כללי החלטה וגבולות ריכוז:

שאלה 1:

צורה 1

$$h = \arg \min_{f: X \rightarrow Y} \mathbb{E} [l_{0-1}(f(x), y)]$$

הצדדים יורד

$$h(x) = \arg \max_{i \in Y} P(y = i | x = x) \quad \text{כמה זיהויים כי}$$

$Y = \{1, \dots, L\}$

חשבו וסקרוה בניה, עתה בנתניה - $X = \bar{x}$

$$\Rightarrow L(h) = \mathbb{E} [l_{0-1}(h(\bar{x}), y)] = \sum_{i=1}^L l_{0-1}(h(\bar{x}), i) \cdot P(x = \bar{x}, y = i)$$

תחת h כותב y

$$\bullet P(x = \bar{x}, y = i) = P(x = \bar{x}) \cdot P(y = i | x = \bar{x})$$

$$\Rightarrow L(h) = P(x = \bar{x}) \cdot \sum_{i=1}^L l_{0-1}(h(\bar{x}), i) \cdot P(y = i | x = \bar{x}) =$$

$$= \begin{cases} P(x = \bar{x}) \cdot \sum_{i=1}^L P(y = i | x = \bar{x}) & h(\bar{x}) = u \\ & u \in Y = \{1, \dots, L\} \end{cases}$$

$$l_{0-1}(h(\bar{x}), i) = \begin{cases} 1 & h(\bar{x}) \neq i \\ 0 & h(\bar{x}) = i \end{cases}$$

$$= \begin{cases} P(x = \bar{x}) \cdot (1 - P(y = u | x = \bar{x})) & h(\bar{x}) = u \end{cases}$$

תקן הצדק המינימלי. $L(h)$ יתקן סוגר

$$h(\bar{x}) = i = \arg \max_{i \in Y} P(y = i | x = \bar{x})$$

כסי מתינו.

שאלה 2:

אנחנו

או, זהו זה...

פונקציה זו הפונקציה!

$$f_0(x, \mu_0, \Sigma) = \frac{1}{2\pi \cdot \sqrt{2}} \cdot e^{-\frac{1}{2} x^T \Sigma^{-1} x} =$$


$$= \frac{1}{2\pi \cdot \sqrt{2}} \cdot e^{-\frac{1}{2} (x_1, x_2) \cdot \begin{pmatrix} 1 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}} =$$

$$= \frac{1}{2\pi \cdot \sqrt{2}} \cdot e^{-\frac{1}{2} (x_1^2 + \frac{1}{2} x_2^2)}$$

$$f_1(x, \mu_1, \Sigma) = \frac{1}{2\pi \cdot \sqrt{2}} \cdot e^{-\frac{1}{2} (x_1 - 1, x_2 - 1) \begin{pmatrix} 1 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} x_1 - 1 \\ x_2 - 1 \end{pmatrix}} =$$

$$= \frac{1}{2\pi \cdot \sqrt{2}} \cdot e^{-\frac{1}{2} ((x_1 - 1)^2 + \frac{1}{2} (x_2 - 1)^2)}$$

הפונקציה, הפונקציה הזו היא הפונקציה הזו.



$$P(y=1|x) > P(y=0|x) \quad (2)$$

$$\Leftrightarrow \frac{f_{x|y=1}(x) \cdot P(y=1)}{f_x(x)} > \frac{f_{x|y=0}(x) \cdot P(y=0)}{f_x(x)}$$

$$P(y=1)=p \Leftrightarrow p \cdot f_1(x, \mu_1, \Sigma_1) > (1-p) \cdot f_0(x, \mu_0, \Sigma_0)$$

$y \in \{0,1\}$

$$-\frac{1}{2}(x-\mu_1)^T \Sigma_1^{-1}(x-\mu_1)$$

$$\Leftrightarrow \frac{1-p}{p} < \frac{e^{-\frac{1}{2}(x-\mu_0)^T \Sigma_0^{-1}(x-\mu_0)}}{e^{-\frac{1}{2}(x-\mu_1)^T \Sigma_1^{-1}(x-\mu_1)}}$$

$$-\frac{1}{2}(x-\mu_1)^T \Sigma_1^{-1}(x-\mu_1) + \frac{1}{2}(x-\mu_0)^T \Sigma_0^{-1}(x-\mu_0)$$

$$\Leftrightarrow \frac{1-p}{p} < e$$

$$\Leftrightarrow \ln\left(\frac{1-p}{p}\right) < (x-\mu_0)^T \Sigma_0^{-1}(x-\mu_0) - (x-\mu_1)^T \Sigma_1^{-1}(x-\mu_1)$$

! Laplace rule, you will get the same result for the two classes.

$$\Leftrightarrow \ln\left(\frac{1-p}{p}\right) < (\mu_1^T - \mu_0^T) \Sigma^{-1} (x - \mu_0 - \mu_1)$$

! This is the decision rule.

(7)

נוויט חשיבה כי סדר $d=1$ קצת בקורה . ניתן אינסופיים - ∞ .

כי קצת $d=2$ קצת ישר .

במקרה , נקרא גיוון כיוון - הגיוון מתחילת הקורס :

$$2 \ln \left(\frac{1-p}{p} \right) = (\mu_1^t - \mu_0^t) Z^{-1} (2x - \mu_0 - \mu_1)$$

$$\Leftrightarrow \underbrace{2 (\mu_1^t - \mu_0^t) Z^{-1} x}_{\text{נקרא}} = \underbrace{2 \ln \left(\frac{1-p}{p} \right) + (\mu_1^t - \mu_0^t) Z^{-1}}_{\text{נקרא}} \cdot (\mu_0 + \mu_1)$$

כיוון הסתברות קרא נוסף d - משהי .


(ה) מסתכל הקורס קראנו מסווגים , כיום את הנתיבים הנכונים μ_0, μ_1, Σ

$$(2, 2) \cdot \begin{pmatrix} 1 & 0 \\ 0 & 1/2 \end{pmatrix} x = 2 \ln \left(\frac{1-p}{p} \right) + (1, 1) \begin{pmatrix} 1 & 0 \\ 0 & 1/2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\Rightarrow (2, 1) x = 2 \ln \left(\frac{1-p}{p} \right) = (1, 1/2) \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\Rightarrow 2x_1 + x_2 = 2 \ln \left(\frac{1-p}{p} \right) + \frac{3}{2}$$

נוסף את המסלול זה מסתבר מסתבר $p = 0.25, 0.5, 0.99$.



$$\frac{1}{\sqrt{2\pi\sigma_1^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma_1^2}} = \frac{1-p}{p} \cdot \frac{1}{\sqrt{2\pi\sigma_0^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma_0^2}} \quad (1)$$

$$\Leftrightarrow \frac{1-p}{p} \cdot \frac{\sigma_0}{\sigma_1} = e^{\frac{(x-\mu)^2}{2} \left(\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2} \right)}$$

$$\Leftrightarrow \ln \left(\frac{1-p}{p} \cdot \frac{\sigma_0}{\sigma_1} \right) = \frac{(x-\mu)^2}{2} \left(\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2} \right)$$

:

$$\Leftrightarrow x = \mu \pm \sigma_0 \sigma_1 \sqrt{\frac{\ln \left(\frac{1-p}{p} \cdot \frac{\sigma_0}{\sigma_1} \right)}{\sigma_1^2 - \sigma_0^2}}$$

(1) תוצאה

שאלה 3:

גיוסה 3

נתון $S = X_1 + \dots + X_n$ ואילו חזית ממונה $N \in \mathbb{N}$ כך שכל $n \geq N$

$$P(S > n^2 + 0.2n) < 0.1$$

$$E[X_i] = \frac{-3+5}{2} = 1, \quad \forall 1 \leq i \leq n$$

$$\bar{X} = \frac{S}{n} = \frac{1}{n} \sum_{i=1}^n X_i$$

כפי שהזכרנו קניית, נאמר

$$E[\bar{X}] = \frac{1}{n} \cdot n = 1$$

$$\Rightarrow P(|\bar{X} - 1| \geq \varepsilon) \leq 2e^{-\frac{\varepsilon^2}{2(S+3)^2} \cdot n}$$

↑
חופפים

כעת,

$$P(S > n^2 + 0.2n) = P\left(\frac{S}{n} > n + 0.2\right) =$$

$$= P(\bar{X} - 1 > n - 0.8) \leq$$

$$= P(|\bar{X} - 1| > n - 0.8) \leq$$

→ אינדיקטור - סופר' התחברו -

$$= \frac{n(n-0.8)^2}{2 \cdot 9^2}$$

$$\leq 2e$$

$$:= \alpha$$

נבחר $\alpha < 0.1$

$$\Rightarrow -\frac{n(n-0.8)^2}{2 \cdot 9^2} < \ln(0.05)$$


$$\Rightarrow n(n-0.8)^2 > -2 \cdot 9^2 \cdot \ln(0.05) \approx 383.45$$

אזל בשאלה. מסתמך ידני - פשוטה נמצא N הנכחי הוא

$$N = 8$$

י.ק. סתמי ויר - הנכחי.

שאלה 4:



מטלה מעשית:


א. הקוד במודל, תחת השם `knn.py`. הפונק' הרלוונטית לסעיף זה היא `knn`.

ב. הדיוק תחת הנתונים הדרושים ($n = 1000$, $k = 10$) היה 84.6%.

הייתי מצפה מפרידיקט רנדומלי דיוק של כ- 10%. זאת כיוון שעבור כל תמונה, תחת הנחת התפלגות אחידה, הסיכוי של ניחוש רנדומלי להיות נכון הוא $1/10$ (שכן ישנם עשרה קלאסטרים – 10 ספרות).

הערה: הקוד לסעיף זה נמצא גם הוא באותו הקובץ. הפונק' הרלוונטית היא `predict`.

ג.




בתוצאות ניתן לראות כי באופן כללי, ככל ש k גדול יותר, כך יורדת רמת הדיוק. בפרט, הדיוק הגבוה ביותר התקבל עבור $k = 1$.

תחילה התוצאות הפתיעו אותי, אך אנסה להסבירן באופן הבא: באופן כללי ב `data` שניתן לאלגוריתם, יש דמיון גבוה בין ה- `train data` וה- `test data`.

על כן, בהתקבל קלט חדש, הוקטור הקרוב ביותר אליו הוא מדד איכותי ביותר. זאת ועוד, שהוספת וקטורים רחוקים יותר למדידות רק תפגע באיכות התוצאה.

מכאן שעבודה עם $k = 1$, כלומר התייחסות רק לוקטור הקרוב ביותר, תיתן את התוצאות הטובות ביותר.

הערה: הקוד לסעיף זה נמצא גם הוא באותו הקובץ. הפונק' הרלוונטית היא `plot_k_accuracy`.



בתוצאות ניתן לראות כי באופן כללי, ככל ש n גדול יותר, כך עולה רמת הדיוק. בפרט, הדיוק הגבוה ביותר התקבל עבור $n = 5000$ (ייתכן כי עבור $n = 4800$, אך כוונתי פה הייתה לדון בתוצאות בצורה מעט יותר סכמטית).

ראשית ברור כי יותר תמונות לאימון ישפרו את דיוק האלגוריתם, שכן בעת קבלת תמונה חדשה, יש סיכוי גבוה יותר שתהיה תמונה עליה התאמנו הנמצאת באותו הקלאסטר וקרובה לתמונה הנמדדת.

דבר מעניין להבחין בו הוא כי מגמת השיפור הופכת להיות משמעותית קטנה יותר בערך כאשר $n > 1400$. הגיוני כי החל מנקודה מסויימת השיפוע יקטן שכן בשלב מסוים יהיו מספיק תמונות מקלאסטרים שונים שנמדדו כך שבסיכוי גבוה תמונה חדשה תמצא קרובה לתמונה שנמדדה כבר ונמצאת באותו הקלאסטר. במצב זה, הוספת תמונות נוספות תתרום פחות משתרמה בהתחלה.

הערה: הקוד לסעיף זה נמצא גם הוא באותו הקובץ. הפונק' הרלוונטית היא `plot_n_accuracy`.