

1 affice

PSD if and only if $A = xx^t$, $A \geq 0 \Leftrightarrow$ every row sum of A is non-negative

if and only if $v^t A v = v^t x x^t v = (x^t v)^t (x^t v) = \|x^t v\|^2 \geq 0$

$$v^t A v = v^t x x^t v = (x^t v)^t (x^t v) = \|x^t v\|^2 \geq 0$$

every row sum of A is non-negative

if and only if $v_i^t A v_i = 0 \Rightarrow A_{ii} \geq 0$ for all i \rightarrow A is non-negative

$$\forall i=1 \dots n, 0 \leq v_i^t A v_i = v_i^t x_i v_i = x_i \cdot \|v_i\|^2 \Rightarrow x_i \geq 0$$

the same for all v_i

\Rightarrow every column sum of A is non-negative \rightarrow $A \geq 0$

($\forall i$ there exists v_i such that $v_i^t A v_i = 0$ \rightarrow $x_i = 0$) \Rightarrow $x = 0$

($\forall i$ there exists v_i such that $v_i^t A v_i = 0$ \rightarrow $x_i = 0$) \Rightarrow $x = 0$

$$\Rightarrow D = \begin{pmatrix} x_1 & & \\ & \ddots & \\ & & x_n \end{pmatrix} = \begin{pmatrix} \sqrt{x_1} & & \\ & \ddots & \\ & & \sqrt{x_n} \end{pmatrix} \begin{pmatrix} \sqrt{x_1} & & \\ & \ddots & \\ & & \sqrt{x_n} \end{pmatrix} =$$

$$= \hat{D} \cdot \hat{D}^t = \hat{D}^t \cdot \hat{D}$$

$$\Rightarrow A = Q D Q^t = Q \hat{D}^t \hat{D} Q^t = (\hat{D} \hat{Q}^t)^t (\hat{D} \hat{Q}^t) = x^t x$$

$$x = \hat{D} \hat{Q}^t$$

* given x we can find Q such that $Q^t Q = I$ and $\hat{Q}^t \hat{Q} = I$ \rightarrow $Q = \hat{Q}^{-1}$

1 ג'KE

כORTHOGONALITY, וORTHOGONALITY

$$x^T A x = x^T \begin{pmatrix} \sum_{j=1}^n A_{ij} x_j \\ \vdots \\ \sum_{j=1}^n A_{nj} x_j \end{pmatrix} = \sum_{i=1}^n x_i \cdot (\sum_{j=1}^n A_{ij} x_j) =$$

$$= \sum_{i=1}^n \sum_{j=1}^n A_{ij} x_i x_j$$

ויהי x מודולו הדרישה:

$$\frac{\partial x^T A x}{\partial x_i} = 1 \cdot \underbrace{\sum_{j=1}^n A_{ij} \cdot x_j}_{\text{הוינט ה-} i\text{-י}} + 1 \cdot \underbrace{\sum_{m=1}^n A_{mi} x_m}_{\text{הוינט ה-} i\text{-י}} \Rightarrow ((A + A^T)x)_i$$

הוינט ה- i -י

הוינט ה- i -י

המוניטור ה- i -י

המוניטור ה- i -י

הוינט

המוניטור

המוניטור

המוניטור

וירטואלי זה.

2 office

$$R(x) = \ln(E[e^{xX}])$$

$$R'(x) = \frac{\frac{d}{dx} E[e^{xX}]}{E[e^{xX}]}$$

לעתה, סבירו לנו פונקציית אנטרופיה. $E[e^{xX}] = \int_{-\infty}^{\infty} e^{xX} f_X(x) dx$ היא מוגדרת כ-

פונקציה רציפה בנקודה $x=0$, ומכיוון שהיא מוגדרת כגבול של פונקציות רציפות, אז ניתן לרשום את הערך כגבול של פונקציות רציפות.

$$\begin{aligned} \frac{d}{dx} E[e^{xX}] &= \frac{d}{dx} \int_{-\infty}^{\infty} e^{xX} f_X(x) dx = \\ &= \int_{-\infty}^{\infty} \frac{d}{dx} e^{xX} f_X(x) dx = \\ &= \int_{-\infty}^{\infty} x e^{xX} f_X(x) dx = E[Xe^{xX}] \end{aligned}$$

ולא נזקירה פונקציית דיריכלי

$$R'(x) = \frac{E[Xe^{xX}]}{E[e^{xX}]}$$

אנו נזכיר את זה:

$$R''(x) = \frac{E[Xe^{xX}]' \cdot E[e^{xX}] - E[Xe^{xX}]' \cdot E[Xe^{xX}]}{(E[e^{xX}])^2}$$

בנוסף, נזכיר $E[e^{xX}]$ הוא מוגדר בנקודה $x=0$ על ידי $E[e^{xX}] = E[X^2 e^{xX}]$ (לפניהם)

$$(E[X^2 e^{xX}])' = E[X^2 e^{xX}]$$

$$\Rightarrow R''(x) = \frac{E[X^2 e^{xX}] E[e^{xX}] - (E[Xe^{xX}])^2}{(E[e^{xX}])^2} =$$

$$= \frac{E[X^2 e^{xX}]}{E[e^{xX}]} - \left(\frac{E[Xe^{xX}]}{E[e^{xX}]} \right)^2$$

... ו... ו... ו...

2) גלום מילוי מילוי - בנסיבות מלחמה, כמו גזע מלחמה → מילוי מילוי → מילוי מילוי → מילוי מילוי → מילוי מילוי .

$$E_g(x) = \int_{-\infty}^{\infty} x \cdot \frac{e^{-\lambda x}}{f_x(x)} f_x(x) dx = E_p(e^{\lambda x})$$

$$= \frac{1}{E[e^{Xx}]} \cdot \int_{-\infty}^{\infty} x e^{Xx} f_X(x) dx = \frac{E[Xe^{Xx}]}{E[e^{Xx}]}$$

$$E_g [e^{X^2}] = \int_{-\infty}^{\infty} x^2 \cdot \frac{e^{-\lambda x}}{E_f [e^{\lambda x}]} f_X(x) dx =$$

$$= \frac{1}{E_f[e^{xx}]} \cdot \int_{-\infty}^{\infty} x^2 \cdot e^{xx} \cdot f_x(x) dx = \frac{E[x^2 e^{xx}]}{E[e^{xx}]}$$

$$\text{Var}_g(x) = E_g[(x^2)] - E_g[x]^2 = \text{Var}_g(x) \quad \Rightarrow \text{Var}_g(x) = E_g[(x^2)] - E_g[x]^2$$

$\text{Var}_g(x) \leq B^2$: primo passo nel riconoscere

$E_g(X^2) \leq B^2$ so $P(X^2 > B^2) \leq 1/B^2$.

$$\Rightarrow \text{var}_g(x) = E_g(x^2) - E_g[x]^2 = E_g[x^2] - B^2$$

ככטוי

$$* R(\lambda)'' = B^2 \quad (2)$$

$$* R(0) = \ln(\mathbb{E}[e^{0 \cdot X}]) = \ln 1 = 0$$

$$* R'(0) = \frac{\mathbb{E}[X e^{0 \cdot X}]}{\mathbb{E}[e^{0 \cdot X}]} = \mathbb{E}[X] = 0$$

$$\int_a^b f(x) dx = F(b) - F(a) \rightarrow \text{Wissen die Formel kennen}$$

$$\Rightarrow \int_0^\infty \int_0^t R''(s) ds dt = \int_0^\infty R'(t) - R'(0) dt = R(\infty) - R(0) = R(\infty)$$

$$\int_0^\infty \int_0^t R''(s) ds dt \approx \int_0^\infty \int_0^t B^2 ds dt = \int_0^\infty t \cdot B^2 dt = B^2 \frac{t^2}{2}$$

$$\Rightarrow \ln(\mathbb{E}[e^{\lambda X}]) \approx B^2 \frac{\lambda^2}{2} \Rightarrow \mathbb{E}[e^{\lambda X}] = e^{B^2 \frac{\lambda^2}{2}}, \forall \lambda \in \mathbb{R}$$

CCU

1 office

$$h = \arg \min_{f: x \mapsto y} \mathbb{E}[l_{0-1}(f(x), y)]$$

$$h(x) = \arg \max_{i \in Y} P(Y=i | X=x) \Rightarrow \text{כדי גורילה} \rightarrow$$

$$= \{1, \dots, c\}$$

$X = \bar{x} - ?$ מוגדרות נסיגות כ- \bar{x} , ו- $\hat{\sigma}_x$ פונקציית

$$\Rightarrow L(h) = \mathbb{E}_{\mathcal{C} \sim \mathcal{D}_{0-1}} [h(\bar{x}), y)] = \sum_{i=1}^n \mathbb{P}(h(\bar{x}) = i) \cdot P(X = \bar{x}, Y = i)$$

$$\bullet \quad P(X = \bar{x}, Y = i) = P(X = \bar{x}) \cdot P(Y = i \mid X = \bar{x})$$

$$\Rightarrow L(h) = \Pr(X = \bar{x}) \cdot \sum_{i=1}^L l_{o-i}(h(\bar{x}), i) \cdot \Pr(Y=i | X = \bar{x}) =$$

$$= \begin{cases} \Pr(X = \bar{x}) \cdot \sum_{\substack{i=1 \\ i \neq k}}^L \Pr(Y=i | X = \bar{x}) & h(\bar{x}) = k \\ 0 & h(\bar{x}) \neq k \end{cases}$$

$$k \in Y = \{1, \dots, L\}$$

$$l_{o-i}(h(\bar{x}), i) = \begin{cases} 1 & h(\bar{x}) \neq i \\ 0 & h(\bar{x}) = i \end{cases}$$

$$= \left\{ \Pr(X = \bar{x}) - (1 - \Pr(Y = \kappa | X = \bar{x})) \right\} h(\bar{x}) = \kappa$$

הו גוף הגוף המורכב מ- n נקודות, ו- m קווים, ו- k משטחים.

$$h(\bar{x}) = i = \arg \max_{i \in \mathcal{Y}} P(y=i | x=\bar{x})$$

ס. עליון.

2 מינימום

... נציג מינימום

לפונקציית פוטון (P)

$$\begin{aligned}f_0(x, \mu_0, \Sigma) &= \frac{1}{2\pi \cdot \sqrt{2}} \cdot e^{-\frac{1}{2} x^T \Sigma^{-1} x} = \\&= \frac{1}{2\pi \cdot \sqrt{2}} \cdot e^{-\frac{1}{2} (x_1, x_2) \cdot \left(\begin{matrix} 1 & \frac{\sigma}{2} \\ 0 & \frac{\sigma}{2} \end{matrix}\right) \left(\begin{matrix} x_1 \\ x_2 \end{matrix}\right)} = \\&= \frac{1}{2\pi \cdot \sqrt{2}} \cdot e^{-\frac{1}{2} (x_1^2 + \frac{1}{2} x_2^2)} = \\f_1(x, \mu_1, \Sigma) &= \frac{1}{2\pi \cdot \sqrt{2}} \cdot e^{-\frac{1}{2} (x_1 - 1)^2 + \frac{1}{2} (x_2 - 1)^2} = \\&= \frac{1}{2\pi \cdot \sqrt{2}} \cdot e\end{aligned}$$

... מינימום בנקודה (\bar{x}_1, \bar{x}_2) , כלומר $\nabla f_0 = 0$

$$P(y=1|x) > P(y=0|x)$$

$$\Leftrightarrow \frac{f_{x|y=1}(x) P(y=1)}{f_x(x)} > \frac{f_{x|y=0}(x) P(y=0)}{f_x(x)}$$

$$P(y=1)=p \Leftrightarrow p \cdot f_1(x, \mu_1, \Sigma_1) > (1-p) \cdot f_0(x, \mu_0, \Sigma_0)$$

$y \in \mathbb{R}^{n+1}$

$$-\frac{1}{2} (x - \mu_1)^T \Sigma^{-1} (x - \mu_1)$$

$$\Leftrightarrow \frac{1-p}{p} < \frac{e}{-\frac{1}{2} (x - \mu_0)^T \Sigma^{-1} (x - \mu_0)}$$

$$-\frac{1}{2} (x - \mu_1)^T \Sigma^{-1} (x - \mu_1) + \frac{1}{2} (x - \mu_0)^T \Sigma^{-1} (x - \mu_0)$$

$$\Leftrightarrow \frac{1-p}{p} < e$$

$$\Leftrightarrow \ln\left(\frac{1-p}{p}\right) < (x - \mu_0)^T \Sigma^{-1} (x - \mu_0) - (x - \mu_1)^T \Sigma^{-1} (x - \mu_1)$$

לפנינו μ_0, μ_1 ו- Σ נתונים ו- x הוא נספחים מהתוצאות

$$\Leftrightarrow \ln\left(\frac{1-p}{p}\right) < (\mu_1^T - \mu_0^T) \Sigma^{-1} (x - \mu_0 - \mu_1)$$

תאילור סדרה נספחים

(7)

לפנינו מושג Γ_{PPS} בדרישת $d=1$. מושג זה מוגדר כטביעה של מושג Γ_{PPS} בדרישת $d=2$ כי Γ_{PPS} בדרישת $d=2$ מוגדר כטביעה של מושג Γ_{PPS} בדרישת $d=1$.

$$\ln \left(\frac{1-\rho}{\rho} \right) = (\mu_1^t - \mu_0^t) z^{-1} (x - \mu_0 - \mu_1)$$

$$\Leftrightarrow \underbrace{z(\mu_1^t - \mu_0^t)}_{\text{טביעה}} z^{-1} x = \ln \left(\frac{1-\rho}{\rho} \right) + \underbrace{(\mu_1^t - \mu_0^t)}_{\text{טביעה}} z^{-1}.$$

טביעה - d טביעה קיימת בזיהויים

μ_0, μ_1, I תומכת בטענה כי $\mu_1^t > \mu_0^t$. נוכיח דענו שטביעה קיימת בזיהויים

$$(x, z) \cdot \begin{pmatrix} 1 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} x = \ln \left(\frac{1-\rho}{\rho} \right) + (1, 1) \begin{pmatrix} 1 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} (1)$$

$$\Rightarrow (x, z) x = \ln \left(\frac{1-\rho}{\rho} \right) = (1, \frac{1}{2}) (1)$$

$$\Rightarrow x_1 + x_2 = \ln \left(\frac{1-\rho}{\rho} \right) + \frac{3}{2}$$

$\rho = 0.25, 0.5, 0.99$ מושג זה בזיהויים

$$\frac{1}{\sqrt{2\pi\sigma_1^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma_1^2}} = \frac{1-\rho}{\rho}$$

$$\frac{1}{\sqrt{2\pi\sigma_0^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma_0^2}} = \frac{(x-\mu)^2}{2} \left(\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2} \right)$$

$$\Leftrightarrow \frac{1-\rho}{\rho} \cdot \frac{\sigma_0}{\sigma_1} = e$$

$$\Leftrightarrow \ln \left(\frac{1-\rho}{\rho} \cdot \frac{\sigma_0}{\sigma_1} \right) = \frac{(x-\mu)^2}{2} \left(\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2} \right)$$

:

$$\Leftrightarrow x = \mu + \sigma_0\sigma_1 \int \frac{\ln \left(\frac{1-\rho}{\rho} \cdot \frac{\sigma_0}{\sigma_1} \right)}{\sigma_1^2 - \sigma_0^2}$$

היברואן מרים כהן.

3 notice

$n \geq N$ גורם $\Rightarrow N \in \mathbb{N}$ מונט רון וויי $s = x_1 + \dots + x_n$ יתנו

$$P(S > n^2 + 0.2n) < 0.1$$

$$+ E(X_i) = \frac{-3 + 5}{2} = 1 \Rightarrow \forall i=1 \dots n$$

$$\bar{x} = \frac{\sum x_i}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$

כפי הנראה, סכום כל ה

$$+ E(\bar{x}) = \frac{1}{3} \cdot n = 1$$

$$\Rightarrow P(|\bar{x} - 1| \geq \epsilon) \leq 2e^{-\frac{\epsilon^2}{2(5+3)^2}} = n$$

۱۰۹

גנוב

$$\begin{aligned} \Pr(S > n^2 + o(\sqrt{n})) &= \Pr\left(\frac{S}{n} > n + o(1)\right) = \\ &= \Pr(\bar{X} - 1 > n - o(\sqrt{n})) \leq \end{aligned}$$

$$-\text{inner } \rho_{10} - \text{inner } \rho_{11} \Rightarrow \mathbb{P}(|\bar{X}_n - 1| > n^{-0.9}) \leq$$

$$= \frac{n(n-0.8)}{2 \cdot 8^2}$$

ပါရာခါ → ၃၂

$$i = \alpha$$

$\alpha < 0.1$ מינימום

$$\Rightarrow - \frac{n(n-0.8)^2}{2 \cdot 1^2} \leftarrow \ln(0.05)$$

$$\Rightarrow n(n - 0.8)^2 > -2 \cdot 8^2 \cdot \ln(0.03) \approx 383.45$$

הנחייה מינה. הנחייה מינה. הנחייה מינה. הנחייה מינה. הנחייה מינה.

$$N = 8$$

וְקַרְבָּן וְקַרְבָּן